

# Studio dei costi di Otello

Variabili:

- U: numero di utenti che usano Otello
- N: numero medio di richieste giornaliere per utente
- $L_i$ : lunghezza media di una query ad Otello (in token, circa 7/10 del numero di parole)
- $L_o$ : lunghezza media di una risposta di Otello (in token)
- $C_i$ : costo di un token in input (in dollari)
- $C_o$ : costo di un token in output (in dollari)
- S: tasso di successo delle richieste
- $K_o$ : lunghezza media di una risposta di *openai completions* (in token)

Il costo generato dal servizio è quindi:

$$U \times N \times ((L_i \times C_i) + (K_o \times C_i) + S \times (L_o \times C_o))^{1,2}$$

Assumendo 10 utenti che effettuano una richiesta al giorno, ogni query di 50 token in input e 200 in output, con un tasso di successo del 75% (considerando fallimenti dovuti a cattivi prompt e richieste non accettate perché fuori dallo scope del chatbot). Fissiamo anche  $K_o$  a 40.

Al 17/1/25 il costo per 1M di token con il modello utilizzato (*gpt-4o-mini*), è \$0.15 in input e \$0.60 in output.<sup>3</sup>

Il totale ammonterebbe quindi a: \$0,001735 al giorno

---

<sup>1</sup> Si potrebbe aggiungere anche il costo delle query a cui Otello non trova una risposta ma che non falliscono, qui sono trattate come semplici fallimenti che non ritornano un output. Il costo sarebbe comunque costante (circa  $\$2.5 \times 10^{-5}$ )

<sup>2</sup> L'input di file agli assistenti (la seconda parte della richiesta) ha un costo di \$0.10, ma il primo GB è incluso. Non prevedendo di caricare più di un GB di dati al giorno questo costo non è considerato. Potrebbe diventare necessario tenerne conto per  $N > 1000$ .

<sup>3</sup> Al momento non è attivata la ricarica automatica, quindi una volta esaurito il credito nell'account *openai* non verranno soddisfatte ulteriori richieste all'API.